


MACHINE LEARNING

Naïve Bayes

Dr. Sirojul Munir, S.Si., M.Kom.
rojulman@nurulfikri.ac.id

ARTIFICIAL INTELLIGENCE – INFORMATICS STTNF



Daur ulang Project Data Science



Algoritma Klasifikasi


1.K- Nearest Neighbors

2.Naive Bayes classifier

3.Decision Trees

4.Support Vector Machine

5.Random Forest



Algoritma Naïve Bayes

Bayes' Theorem

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

Probability of B when A has already occurred (points to $P(B|A)$)
 Probability of A (points to $P(A)$)
 Probability of B (points to $P(B)$)
 Probability of A when B has already occurred (points to $P(A|B)$)



Thomas Bayes
1702 - 1761

- Algoritma Klasifikasi berbasis **Probabilitas** di masa depan berdasarkan pengalaman di masa sebelumnya
- Menggunakan **Teorema Bayes** untuk menghitung kemungkinan sebuah **data masuk ke kelas tertentu**
- Disebut "**naive**" karena mengasumsikan setiap fitur saling independent (tidak saling memengaruhi).



Rumus Dasar Algoritma Naïve Bayes

$$P(C|X) = \frac{P(X|C) P(C)}{P(X)}$$

Keterangan:

- $P(C|X)$: Probabilitas kelas C diberikan data $X \rightarrow$ hasil prediksi.
- $P(X|C)$: Probabilitas fitur X muncul pada kelas C .
- $P(C)$: Probabilitas awal (prior) dari kelas C .
- $P(X)$: Probabilitas fitur X secara keseluruhan.

Case Study :: Cacat Kunci Pas



Berapa Probabilitas produk cacat dari mesin 2 ?



m2



Case Study :: Cacat Kunci Pas

1. Definisi Variabel

- C = "defect" → kondisi kunci pas cacat
- $M1$ = mesin 1 menghasilkan kunci pas
- $M2$ = mesin 2 menghasilkan kunci pas
- Ditanyakan: $P(C | M2)$

Probabilitas produk cacat
dari mesin 2 ?

2. Dari data:

- Produksi $M1$ = 30 unit/hari
- Produksi $M2$ = 20 unit/hari
- Total produksi = 50 unit/hari
- Tingkat cacat total (gabungan) = 1%
- Tidak diberikan tingkat cacat per mesin → diasumsikan sama, yaitu

$$P(C | M1) = P(C | M2) = 0.01$$

- Dari seluruh produk cacat,
50% berasal dari mesin 1
50% berasal dari mesin 2

Artinya:

$$P(M1 | C) = 0.5$$

$$P(M2 | C) = 0.5$$

Case Study :: Cacat Kunci Pas

Kita gunakan informasi:

- $P(M2 | C) = 0.5$ (50% dari barang cacat berasal dari mesin 2)
- $P(C) = 0.01$ (1% dari seluruh produksi cacat)
- $P(M2) = \frac{20}{50} = 0.4$

Probabilitas produk cacat dari mesin 2 ?

Kita ingin mencari:

$$P(C | M2)$$

Gunakan rumus Bayes:

$$P(M2 | C) = \frac{P(C | M2) P(M2)}{P(C)}$$

Substitusi angka:

$$0.5 = \frac{P(C | M2) (0.4)}{0.01}$$

Selesaikan:

$$P(C | M2) = \frac{0.5 \times 0.01}{0.4}$$

$$P(C | M2) = \frac{0.005}{0.4} = 0.0125$$

✓ **Probabilitas bahwa produk dari mesin 2 adalah cacat:**

$$P(C | M2) = 0.0125 = 1.25\%$$

Case Study :: Menentukan objek Perumahan

- ✓ Ingin diketahui apakah suatu objek masuk dalam kategori dipilih untuk dijadikan perumahan atau tidak dengan algoritma Naive Bayes Classifier.
- ✓ Untuk menetapkan suatu daerah akan dipilih sebagai lokasi untuk mendirikan perumahan, telah dihimpun 10 data.
- ✓ Ada 4 atribut yang digunakan, yaitu:
 1. harga tanah per meter persegi (C1),
 2. jarak daerah tersebut dari pusat kota (C2),
 3. ada atau tidaknya angkutan umum di daerah tersebut (C3), dan
 4. Keputusan untuk memilih daerah tersebut sebagai lokasi perumahan (C4).

Aturan ke-	Atribut / Parameter			Label / Kelas
	Harga tanah (C1)	Jarak dari pusat kota (C2)	Ada angkutan umum (C3)	Dipilih untuk perumahan (C4)
1	Murah	Dekat	Tidak	Ya
2	Sedang	Dekat	Tidak	Ya
3	Mahal	Dekat	Tidak	Ya
4	Mahal	Jauh	Tidak	Tidak
5	Mahal	Sedang	Tidak	Tidak
6	Sedang	Jauh	Ada	Tidak
7	Murah	Jauh	Ada	Tidak
8	Murah	Sedang	Tidak	Ya
9	Mahal	Jauh	Ada	Tidak
10	Sedang	Sedang	Ada	Ya

Case Study :: Menentukan objek Perumahan

✓ Probabilitas Atribut C1 :: Harga Tanah

Harga tanah	Jumlah kejadian "Dipilih"		Probabilitas	
	Ya	Tidak	Ya	Tidak
Murah	2	1	2/5	1/5
Sedang	2	1	2/5	1/5
Mahal	1	3	1/5	3/5
Jumlah	5	5	1	1

✓ Probabilitas Atribut C3 :: Ada Angkutan umum

Angkutan Umum	Jumlah kejadian "Dipilih"		Probabilitas	
	Ya	Tidak	Ya	Tidak
Ada	1	3	1/5	3/5
Tidak	4	2	4/5	2/5
Jumlah	5	5	1	1

✓ Probabilitas Atribut C2 :: Jarak dari pusat Kota

Jarak Dari Pusat Kota	Jumlah kejadian "Dipilih"		Probabilitas	
	Ya	Tidak	Ya	Tidak
Dekat	3	0	3/5	0
Sedang	2	1	2/5	1/5
Jauh	0	4	0	4/5
Jumlah	5	5	1	1

✓ Probabilitas Atribut C4 :: Pilih Menjadi Perumahan

Dipilih Untuk Perumahan	Jumlah kejadian "Dipilih"		Probabilitas	
	Ya	Tidak	Ya	Tidak
Jumlah	5	5	1/2	1/2

↑
5/10

↑
5/10

Case Study :: Menentukan objek Perumahan

✓ Klasifikasi Data Uji

Apabila diketahui suatu daerah dengan informasi:

1. harga tanah (C1)= **MAHAL**,
2. Jarak dari pusat kota (C2)= **SEDANG**, dan
3. Angkutan umum (C3) = **ADA**,
4. Maka apakah daerah tersebut dapat dipilih untuk perumahan atau tidak?

$$\begin{aligned}\checkmark \text{ YA} &= P(\text{Ya} | \text{Tanah}=\text{MAHAL}) \times P(\text{Ya} | \text{Jarak}=\text{SEDANG}) \times P(\text{Ya} | \text{Angkutan}=\text{ADA}) \times P(\text{Ya}) \\ &= 1/5 \times 2/5 \times 1/5 \times 5/10 = \mathbf{10/1250} = 0,008\end{aligned}$$

$$\begin{aligned}\checkmark \text{ TIDAK} &= P(\text{Tidak} | \text{Tanah}=\text{MAHAL}) \times P(\text{Tidak} | \text{Jarak}=\text{SEDANG}) \times P(\text{Tidak} | \text{Angkutan}=\text{ADA}) \times P(\text{Tidak}) \\ &= 3/5 \times 1/5 \times 3/5 \times 5/10 = \mathbf{45/1250} = 0,036\end{aligned}$$

Case Study :: Menentukan objek Perumahan

✓ Klasifikasi Data Uji

Nilai probabilitas dapat dihitung dengan melakukan normalisasi terhadap likelihood tersebut sehingga jumlah nilai yang diperoleh = 1

$$\begin{array}{lcl} \text{Probabilitas Ya} = & \frac{0,008}{0,008 + 0,036} = 0,182. & \\ \text{Probabilitas Tidak} = & \frac{0,036}{0,008 + 0,036} = 0,818. & \end{array} \left. \vphantom{\begin{array}{l} \text{Probabilitas Ya} \\ \text{Probabilitas Tidak} \end{array}} \right\} \text{Klasifikasi : TIDAK}$$

Karena probabilitas **TIDAK (0,818)** lebih besar daripada **YA (0,182)**, maka tanah tersebut **TIDAK** cocok dijadikan perumahan

Case Study :: Menentukan objek Perumahan

✓ Membuat DataFrame

```
import pandas as pd
from sklearn.preprocessing import LabelEncoder
from sklearn.naive_bayes import CategoricalNB

# =====
# 1. MEMBUAT DATAFRAME
# =====

data = {
    "C1": ["Murah", "Sedang", "Mahal", "Mahal", "Mahal", "Sedang", "Murah", "Murah", "Mahal", "Sedang"],
    "C2": ["Dekat", "Dekat", "Dekat", "Jauh", "Sedang", "Jauh", "Jauh", "Sedang", "Jauh", "Sedang"],
    "C3": ["Tidak", "Tidak", "Tidak", "Tidak", "Tidak", "Ada", "Ada", "Tidak", "Ada", "Ada"],
    "C4": ["Ya", "Ya", "Ya", "Tidak", "Tidak", "Tidak", "Tidak", "Ya", "Tidak", "Ya"]
}

df = pd.DataFrame(data)
print("=== DataFrame Awal ===")
print(df)
```

Aturan ke-	Atribut / Parameter			Label / Kelas
	Harga tanah (C1)	Jarak dari pusat kota (C2)	Ada angkutan umum (C3)	Dipilih untuk perumahan (C4)
1	Murah	Dekat	Tidak	Ya
2	Sedang	Dekat	Tidak	Ya
3	Mahal	Dekat	Tidak	Ya
4	Mahal	Jauh	Tidak	Tidak
5	Mahal	Sedang	Tidak	Tidak
6	Sedang	Jauh	Ada	Tidak
7	Murah	Jauh	Ada	Tidak
8	Murah	Sedang	Tidak	Ya
9	Mahal	Jauh	Ada	Tidak
10	Sedang	Sedang	Ada	Ya

Case Study :: Menentukan objek Perumahan

✓ Pelabelan / Encoding : C1, C2, C3, C4

```
# =====
# 2. ENCODING LABEL (C1, C2, C3, C4)
# =====

encoders = {col: LabelEncoder() for col in df.columns}

for col in df.columns:
    df[col + "_enc"] = encoders[col].fit_transform(df[col])

print("\n=== DataFrame Setelah Encoding ===")
print(df)
```

Aturan ke-	Atribut / Parameter			Label / Kelas
	Harga tanah (C1)	Jarak dari pusat kota (C2)	Ada angkutan umum (C3)	Dipilih untuk perumahan (C4)
1	Murah	Dekat	Tidak	Ya
2	Sedang	Dekat	Tidak	Ya
3	Mahal	Dekat	Tidak	Ya
4	Mahal	Jauh	Tidak	Tidak
5	Mahal	Sedang	Tidak	Tidak
6	Sedang	Jauh	Ada	Tidak
7	Murah	Jauh	Ada	Tidak
8	Murah	Sedang	Tidak	Ya
9	Mahal	Jauh	Ada	Tidak
10	Sedang	Sedang	Ada	Ya

=== DataFrame Setelah Encoding ===

	C1	C2	C3	C4	C1_enc	C2_enc	C3_enc	C4_enc
0	Murah	Dekat	Tidak	Ya	1	0	1	1
1	Sedang	Dekat	Tidak	Ya	2	0	1	1
2	Mahal	Dekat	Tidak	Ya	0	0	1	1
3	Mahal	Jauh	Tidak	Tidak	0	1	1	0
4	Mahal	Sedang	Tidak	Tidak	0	2	1	0
5	Sedang	Jauh	Ada	Tidak	2	1	0	0
6	Murah	Jauh	Ada	Tidak	1	1	0	0
7	Murah	Sedang	Tidak	Ya	1	2	1	1
8	Mahal	Jauh	Ada	Tidak	0	1	0	0
9	Sedang	Sedang	Ada	Ya	2	2	0	1

Case Study :: Menentukan objek Perumahan

✓ Data Training

```
# =====  
# 3. PERSIAPAN DATA TRAINING  
# =====  
  
X = df[["C1_enc", "C2_enc", "C3_enc"]]  
y = df["C4_enc"]  
  
# =====  
# 4. MEMBANGUN MODEL NAIVE BAYES  
# =====  
|  
model = CategoricalNB()  
model.fit(X, y)
```

CategoricalNB		
Parameters		
alpha	1.0	
force_alpha	True	
fit_prior	True	
class_prior	None	
min_categories	None	

✓ Data Testing

```
# =====  
# 5. PREDIKSI KASUS: MAHAL, SEDANG, ADA  
# =====  
sample = [[  
    encoders["C1"].transform(["Mahal"])[0],  
    encoders["C2"].transform(["Sedang"])[0],  
    encoders["C3"].transform(["Ada"])[0]  
]]  
probabilities = model.predict_proba(sample)[0]  
prediction = model.predict(sample)[0]  
prediction_label = encoders["C4"].inverse_transform([prediction])[0]  
  
print("\n=== HASIL PREDIKSI ===")  
print("Probabilitas Tidak dipilih:", probabilities[0])  
print("Probabilitas Dipilih:", probabilities[1])  
print("Kesimpulan Prediksi:", prediction_label)
```

=== HASIL PREDIKSI ===

Probabilitas Tidak dipilih: 0.7272727272727274

Probabilitas Dipilih: 0.27272727272727276

Kesimpulan Prediksi: Tidak

Case Study :: Menentukan objek Perumahan

✓ Visualisasi – Bar Chart

```
import matplotlib.pyplot as plt
# Probabilitas hasil prediksi Naive Bayes
prob_tidak = probabilities[0]
prob_ya = probabilities[1]


labels = ["Tidak", "Ya"]
values = [prob_tidak, prob_ya]

# Membuat bar chart dengan warna khusus dan grid
plt.figure(figsize=(6,4))
plt.bar(labels, values, width=0.5, color=["#FF8C00", "#1E90FF"])

plt.title("Visualisasi Probabilitas Prediksi")
plt.ylabel("Probabilitas")
plt.ylim(0, 1)

# Menambahkan grid
plt.grid(axis="y", linestyle="--", alpha=0.6)

plt.show()
```




Case Study :: Menentukan objek Perumahan

✓ Visualisasi – Confusion Matrix

```
from sklearn.metrics import confusion_matrix
# =====
# CONFUSION MATRIX
# =====
y_pred = model.predict(X)
cm = confusion_matrix(y, y_pred)


plt.figure(figsize=(5,4))
plt.imshow(cm, interpolation='nearest')
plt.title("Confusion Matrix")
plt.xlabel("Predicted")
plt.ylabel("Actual")
plt.colorbar()
plt.xticks([0,1], ["Tidak", "Ya"])
plt.yticks([0,1], ["Tidak", "Ya"])
plt.show()

print(cm)
```



```
[[4 1]
 [0 5]]
```

Aplikasi Algoritma Naïve Bayes



1. Spam Filtering
2. Medical Diagnosis
3. Weather Prediction
4. Face Recognition
5. Text Classification
6. Sentiment Analysis
7. Recommendation System

Aplikasi Algoritma Naïve Bayes

1. Spam Filtering :: <https://www.kaggle.com/code/pavelbogdanov/spam-filtering-with-naive-bayes>
2. Medical Diagnosis :: <https://www.kaggle.com/code/nisasoylu/naive-bayes-implementation-on-cancer-dataset>
3. Weather Prediction :: <https://www.kaggle.com/code/kelvinprawtama/weather-prediction-using-naive-bayes-algorithm>
4. Face Recognition :: <https://www.kaggle.com/code/nadaahassan/face-recognition>
5. Text Classification :: <https://www.kaggle.com/code/nargisbegum82/naive-bayes-for-text-classification>
6. Sentiment Analysis :: <https://www.kaggle.com/code/ankumagawa/sentimental-analysis-using-naive-bayes-classifier>
7. Recommendation System :: <https://www.kaggle.com/code/amirhosseinzinati/bank-personal-loan-naive-bayes>



Terima Kasih

<http://youtube.com/@rojulman>